

```

1 !pip -q uninstall -y NDETCStemmer NDETCStemmer-kaenova
2 !pip -q install Sastrawi pandas tabulate Levenshtein
3 !pip -q install NDETCStemmer-kaenova
4 !pip -q install --upgrade git+https://github.com/ariaghora/mpstemmer.git

```

WARNING: Skipping NDETCStemmer as it is not installed.

WARNING: Skipping NDETCStemmer-kaenova as it is not installed.

```

_____ 209.7/209.7 kB 5.3 MB/s eta 0:00:00
_____ 153.3/153.3 kB 9.3 MB/s eta 0:00:00
_____ 3.2/3.2 MB 47.2 MB/s eta 0:00:00
_____ 141.8/141.8 kB 4.8 MB/s eta 0:00:00
_____ 27.9/27.9 MB 35.9 MB/s eta 0:00:00

```

Preparing metadata (setup.py) ... done

Building wheel for mpstemmer (setup.py) ... done

✧ Import Library

Pada tahap ini dilakukan import library yang dibutuhkan untuk proses stemming dan penampilan hasil dalam bentuk tabel.

```

1 import pandas as pd
2 from tabulate import tabulate
3
4 from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
5 from NDETCStemmer import NDETCStemmer
6 from mpstemmer import MPStemmer

```

✧ Inisialisasi Stemmer

Setelah seluruh library berhasil diimpor, langkah berikutnya adalah membuat objek stemmer dari masing-masing library agar dapat digunakan untuk proses stemming.

```

1 # Inisialisasi Sastrawi
2 factory = StemmerFactory()
3 sastrawi_stemmer = factory.create_stemmer()
4
5 # Inisialisasi NDETCStemmer
6 ndetc_stemmer = NDETCStemmer()
7
8 # Inisialisasi MPStemmer
9 mp_stemmer = MPStemmer()

```

/usr/local/lib/python3.12/dist-packages/huggingface_hub/utils/_auth.py:94: UserWarning:

The secret `HF\_TOKEN` does not exist in your Colab secrets.

To authenticate with the Hugging Face Hub, create a token in your settings tab (<https://huggingface.co/settings/tokens>), set it You will be able to reuse this secret in all of your notebooks.

Please note that authentication is recommended but still optional to access public models or datasets.

warnings.warn(

Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster d WARNING:huggingface_hub.utils._http:Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to en

w2vec_wiki_id_case: 100% 26.7M/26.7M [00:00<00:00, 133MB/s]

w2vec_wiki_id_case.trainables.syn1neg.np(...): 100% 328M/328M [00:03<00:00, 739MB/s]

w2vec_wiki_id_case.wv.vectors.npy: 100% 328M/328M [00:03<00:00, 161MB/s]

✧ Pembuatan Variabel Data Uji

Pada tahap ini dibuat empat variabel data uji sesuai instruksi tugas, yaitu kata berimbuhan awalan, kata berimbuhan akhiran, kata berimbuhan konfiks, dan kata dengan pola khusus seperti pengulangan atau bentuk tidak baku.

```

1 # Variable1: 10 kata berimbuhan awalan / prefix
2 variable1 = [
3     "membaca", "menulis", "berjalan", "terjatuh", "pengguna",
4     "pelari", "sejarawan", "dikerjakan", "peminum", "ketawa"
5 ]
6
7 # Variable2: 10 kata berimbuhan akhiran / suffix
8 variable2 = [

```

```

9     "makanan", "tulisan", "mainan", "bacaan", "minuman",
10    "jualan", "kiriman", "mandikan", "rapikan", "hormati"
11 ]
12
13 # Variable3: 10 kata berimbuhan confix / gabungan prefiks + sufiks
14 variable3 = [
15     "permainan", "keindahan", "berlarian", "membacakan", "dinyatakan",
16     "pengiriman", "kebersihan", "pemanasan", "menyanyikan", "diperbaiki"
17 ]
18
19 # Variable4: 10 kata berpola khusus
20 variable4 = [
21     "buku-buku", "lari-larian", "sayur-mayur", "gerigi", "telunjuk",
22     "ngechat", "ngelihat", "berbalas-balasan", "meniru-nirukannya", "kebayang"
23 ]
24
25 print("Variable1 =", variable1)
26 print("Variable2 =", variable2)
27 print("Variable3 =", variable3)
28 print("Variable4 =", variable4)

```

```

Variable1 = ['membaca', 'menulis', 'berjalan', 'terjatuh', 'pengguna', 'pelari', 'sejarawan', 'dikerjakan', 'peminum', 'ketawa']
Variable2 = ['makanan', 'tulisan', 'mainan', 'bacaan', 'minuman', 'jualan', 'kiriman', 'mandikan', 'rapikan', 'hormati']
Variable3 = ['permainan', 'keindahan', 'berlarian', 'membacakan', 'dinyatakan', 'pengiriman', 'kebersihan', 'pemanasan', 'menyan
Variable4 = ['buku-buku', 'lari-larian', 'sayur-mayur', 'gerigi', 'telunjuk', 'ngechat', 'ngelihat', 'berbalas-balasan', 'meniru

```

✦ Pembuatan Fungsi Stemmer

Untuk mempermudah proses pengujian, dibuat tiga fungsi yang masing-masing mewakili satu library stemmer. Dengan demikian, setiap kata dapat diproses menggunakan tiga pendekatan stemming yang berbeda.

```

1 def fungsi1_sastrawi(kata):
2     return sastrawi_stemmer.stem(kata)
3
4 def fungsi2_ndetc(kata):
5     return ndetc_stemmer.stem(kata)
6
7 def fungsi3_mpstemmer(kata):
8     return mp_stemmer.stem(kata)

```

✦ Hasil Perbandingan Stemming

Berikut adalah hasil perbandingan stemming pada empat kelompok kata uji, yaitu kata berimbuhan awalan, akhiran, konfiks, serta kata dengan pola khusus. Perbandingan dilakukan menggunakan tiga library, yaitu Sastrawi, NDETCStemmer, dan MPStemmer, untuk melihat perbedaan hasil stemming pada masing-masing kata.

```

1 def bandingkan_stemmer(nama_variabel, daftar_kata):
2     data = []
3     for kata in daftar_kata:
4         data.append({
5             "Variabel": nama_variabel,
6             "Kata Asli": kata,
7             "Sastrawi": fungsi1_sastrawi(kata),
8             "NDETCStemmer": fungsi2_ndetc(kata),
9             "MPStemmer": fungsi3_mpstemmer(kata)
10        })
11    return pd.DataFrame(data)
12
13 df1 = bandingkan_stemmer("Variable1_Prefix", variable1)
14 df2 = bandingkan_stemmer("Variable2_Suffix", variable2)
15 df3 = bandingkan_stemmer("Variable3_Confix", variable3)
16 df4 = bandingkan_stemmer("Variable4_Khusus", variable4)
17
18 print("=== HASIL VARIABLE 1 ===")
19 print(tabulate(df1, headers="keys", tablefmt="grid", showindex=False))
20
21 print("\n=== HASIL VARIABLE 2 ===")
22 print(tabulate(df2, headers="keys", tablefmt="grid", showindex=False))
23
24 print("\n=== HASIL VARIABLE 3 ===")
25 print(tabulate(df3, headers="keys", tablefmt="grid", showindex=False))

```

26

27 print("\n=== HASIL VARIABLE 4 ===")

28 print(tabulate(df4, headers="keys", tablefmt="grid", showindex=False))

Variable2_Suffix	kiriman	kirim	kirim	kirim
Variable2_Suffix	mandikan	mandi	mandi	mandi
Variable2_Suffix	rapikan	rapi	rapik	rapi
Variable2_Suffix	hormati	hormat	hormat	hormat

=== HASIL VARIABLE 3 ===

Variabel	Kata Asli	Sastrawi	NDETCStemmer	MPStemmer
Variable3_Confix	permainan	main	main	main
Variable3_Confix	keindahan	indah	indah	indah
Variable3_Confix	berlarian	lari	lari	lari
Variable3_Confix	membacakan	baca	baca	baca
Variable3_Confix	dinyatakan	nyata	nyata	nyata
Variable3_Confix	pengiriman	kirim	kirim	kirim
Variable3_Confix	kebersihan	bersih	bersih	bersih
Variable3_Confix	pemanasan	panas	panas	panas
Variable3_Confix	menyanyikan	nyanyi	nyanyi	menyanyikan
Variable3_Confix	diperbaiki	baik	baik	baik

=== HASIL VARIABLE 4 ===

Variabel	Kata Asli	Sastrawi	NDETCStemmer	MPStemmer
Variable4_Khusus	buku-buku	buku	buku	buku-buku
Variable4_Khusus	lari-larian	lari	lari	lari-larian
Variable4_Khusus	sayur-mayur	sayur-mayur	mayur	sayur-mayur
Variable4_Khusus	gerigi	gerigi	gerigi	gerigi
Variable4_Khusus	telunjuk	telunjuk	telunjuk	telunjuk
Variable4_Khusus	ngechat	ngechat	ngechat	ngechat
Variable4_Khusus	ngelihat	ngelihat	lihat	lihat
Variable4_Khusus	berbalas-balasan	balas	balas	berbalas-balasan
Variable4_Khusus	meniru-nirukannya	tiru	tiru	meniru-nirukannya
Variable4_Khusus	kebayang	bayang	bayang	bayang

✧ Penggabungan Seluruh Hasil

Seluruh hasil perbandingan dari keempat variabel kemudian digabungkan ke dalam satu tabel agar lebih mudah dibaca dan dianalisis secara keseluruhan.

```
1 hasil_akhir = pd.concat([df1, df2, df3, df4], ignore_index=True)
2
3 print("=== SEMUA HASIL DIGABUNG ===")
4 print(tabulate(hasil_akhir, headers="keys", tablefmt="grid", showindex=False))
```

Variable2_Suffix	jualan	jual	jual	jual
Variable2_Suffix	kiriman	kirim	kirim	kirim
Variable2_Suffix	mandikan	mandi	mandi	mandi
Variable2_Suffix	rapikan	rapi	rapik	rapi
Variable2_Suffix	hormati	hormat	hormat	hormat
Variable3_Confix	permainan	main	main	main
Variable3_Confix	keindahan	indah	indah	indah
Variable3_Confix	berlarian	lari	lari	lari
Variable3_Confix	membacakan	baca	baca	baca
Variable3_Confix	dinyatakan	nyata	nyata	nyata
Variable3_Confix	pengiriman	kirim	kirim	kirim
Variable3_Confix	kebersihan	bersih	bersih	bersih
Variable3_Confix	pemanasan	panas	panas	panas
Variable3_Confix	menyanyikan	nyanyi	nyanyi	menyanyikan
Variable3_Confix	diperbaiki	baik	baik	baik
Variable4_Khusus	buku-buku	buku	buku	buku-buku
Variable4_Khusus	lari-larian	lari	lari	lari-larian
Variable4_Khusus	sayur-mayur	sayur-mayur	mayur	sayur-mayur
Variable4_Khusus	gerigi	gerigi	gerigi	gerigi
Variable4_Khusus	telunjuk	telunjuk	telunjuk	telunjuk
Variable4_Khusus	ngechat	ngechat	ngechat	ngechat
Variable4_Khusus	ngelihat	ngelihat	lihat	lihat
Variable4_Khusus	berbalas-balasan	balas	balas	berbalas-balasan
Variable4_Khusus	meniru-nirukannya	tiru	tiru	meniru-nirukannya
Variable4_Khusus	kebayang	bayang	bayang	bayang

▼ Penyimpanan Hasil

Hasil akhir disimpan ke dalam file CSV agar dapat digunakan kembali sebagai dokumentasi atau bahan analisis lanjutan.

```
1 hasil_akhir.to_csv("hasil_perbandingan_3_stemmer.csv", index=False)
2 print("File hasil_perbandingan_3_stemmer.csv berhasil disimpan")
```

File hasil_perbandingan_3_stemmer.csv berhasil disimpan

Kesimpulan

Berdasarkan hasil ujicoba tiga library stemmer Python, dapat disimpulkan bahwa ketiga library mampu melakukan proses stemming kata berbahasa Indonesia, tetapi hasilnya tidak selalu sama pada semua jenis kata.

1. **Sastrawi** cenderung stabil untuk kata baku dengan pola imbuhan umum. Hal ini terlihat pada kata seperti **membaca**, **berjalan**, **membacakan**, dan **pengiriman** yang berhasil diubah menjadi bentuk dasar dengan baik.
2. **NDETCStemmer** juga memberikan hasil yang baik pada banyak kata, tetapi pada beberapa kasus menghasilkan bentuk yang sedikit berbeda, misalnya kata **rapikan** menjadi **rapik**.
3. **MPStemmer** cukup baik pada banyak kata umum, tetapi pada beberapa kata tertentu masih kurang konsisten, misalnya kata **menyanyikan** tetap menjadi **menyanyikan**, sedangkan Sastrawi dan NDETCStemmer mengubahnya menjadi **nyanyi**.
4. Pada kata nonbaku atau bentuk percakapan, terlihat perbedaan yang cukup jelas. Contohnya pada kata **ngelepas**, Sastrawi tidak mengubah kata tersebut, sedangkan NDETCStemmer dan MPStemmer berhasil menghasilkan bentuk dasar **lepas**.

5. Pada kata berpola khusus seperti pengulangan, hasil stemming antar library juga berbeda. Contohnya `buku-buku` dan `lari-larian` berhasil disederhanakan oleh Sastrawi dan NDETCStemmer, tetapi MPStemmer tetap mempertahankan bentuk awalnya.
6. Dari hasil tersebut dapat disimpulkan bahwa setiap library memiliki pendekatan dan aturan stemming yang berbeda, sehingga hasilnya juga dapat berbeda tergantung jenis kata yang diuji.

Secara umum, **Sastrawi** dan **NDETCStemmer** terlihat lebih konsisten untuk banyak kata baku dan beberapa kata berimbuhan, sedangkan **MPStemmer** memiliki kelebihan pada beberapa kasus tetapi masih kurang konsisten pada kata tertentu. Oleh karena itu, pemilihan library stemmer sebaiknya disesuaikan dengan karakteristik data yang digunakan.