

RESUME JURNAL & KOMPARASI

Nama : Calvin Rifansyah Ardhana

NIM : 200411100072

Kelas : Penambangan Teks B

Jurnal 1 COVID-19 Vaccine Hesitancy on Social Media (AvaxTweets)

1. Judul

Judul: COVID-19 Vaccine Hesitancy on Social Media: Building a Public Twitter Data Set of Antivaccine Content, Vaccine Misinformation, and Conspiracies.

Penulis: Goran Muric; Yusong Wu; Emilio Ferrara (University of Southern California).

Publikasi: JMIR Public Health and Surveillance, 2021;7(11):e30642. DOI: 10.2196/30642.

2. Data

Sumber data: Twitter (tweet dan akun publik), dikumpulkan menggunakan Twitter Streaming API (koleksi streaming) dan Twitter Academic Research API (koleksi historis berbasis akun).

Skala data (dua koleksi utama):

- Streaming collection: 1.832.333 tweet dari 719.652 akun, rentang waktu 18 Okt 2020–21 Apr 2021.
- Account collection (historis): 135.949.773 tweet dari 78.954 akun, rentang waktu 6 Mar 2007–2 Feb 2021.

Bentuk data yang dipublikasikan: daftar Tweet ID (bukan teks penuh), agar sesuai dengan ketentuan redistribusi Twitter. Peneliti dapat “hydrate” Tweet ID via API Twitter untuk memperoleh teks dan metadata yang masih tersedia.

Fitur/atribut yang dimanfaatkan:

- Konten: teks, hashtag, URL, retweet/original.
- Metadata akun: mis. lokasi yang dilaporkan sendiri; status verifikasi.
- Domain berita yang dibagikan (untuk bias politik & kredibilitas).
- Waktu posting (tren temporal).

3. Proses (metodologi)

(a) Pemilihan kata kunci (streaming)

Teknik snowballing: mulai dari seed hashtag yang kuat bernuansa antivaksin, tarik data 1 hari (18 Okt 2020), ambil kata kunci ko-occur, lalu tambah setelah verifikasi manual. Proses diulang sampai stabil, menghasilkan sekitar 60 kata kunci/substring.

(b) Pengumpulan data

- Streaming collection: dimulai 18 Okt 2020 dengan kata kunci antivaksin.
- Account collection: memilih ~70.000 akun yang terlibat narasi antivaksin (Okt–Des 2020), lalu menarik hampir semua tweet historisnya via Academic Research API.

(c) Enrichment & analisis

- Bias politik akun: “media diet” berdasarkan bias outlet yang dibagikan (rating AllSides).
- Kredibilitas domain: pencocokan ke Iffy+ dan pemeriksaan tambahan via Media Bias/Fact Check; URL pendek diekspansi.
- Geolokasi: lokasi akun → negara/negara bagian AS; metrik per kapita dinormalisasi sensus 2010.
- Topic network: jaringan ko-okurensi hashtag; komunitas memakai algoritma Louvain.

4. Model

Catatan: fokus artikel adalah pembangunan & karakterisasi dataset, bukan pelatihan model prediksi end-to-end.

Model/algoritme yang digunakan:

- Louvain (community detection): memetakan kluster narasi dari ko-okurensi hashtag.
- Skor bias politik berbasis media diet: memposisikan akun pada spektrum politik.
- Pipeline URL (parsing, ekspansi, tagging kredibilitas): menilai sumber informasi yang dibagikan.
- Normalisasi geospasial (tweet per juta penduduk): membandingkan aktivitas antar wilayah.

5. Hasil (temuan utama)

- Dataset publik terdiri dari dua koleksi: streaming (>1,8 juta tweet) dan historis akun (>135 juta tweet), dibagikan sebagai Tweet ID.
- Streaming didominasi tweet dari negara berbahasa Inggris; porsi terbesar dari AS.
- Hashtag menonjol mencakup tag umum (#vaccine, #covid19), tag antivaksin (#novaccineforme, #vaxxed, #vaccineinjury), dan tag konspirasi (#depopulation, #billgatesbioterrorist).
- Domain yang dibagikan banyak berasal dari situs kredibilitas rendah; beberapa tautan ke NCBI/PubMed sering dipakai dengan kesimpulan menyesatkan.
- Akun antivaksin cenderung condong ke kanan (konservatif).
- Analisis Louvain menemukan 3 kluster utama: konspirasi depopulasi/elit global, isu keamanan/cedera vaksin, dan kluster campuran antivaksin–netral–pro-vaksin.

Keterbatasan: bergantung kata kunci (lingo berubah), bias bahasa Inggris, dan hidrasi Tweet ID bisa tidak lengkap karena akun/tweet dihapus/ditangguhkan.

Jurnal 2 Tracing the Pace of COVID-19 Research: Topic Modeling and Evolution

1. Judul

Judul: Tracing the Pace of COVID-19 Research: Topic Modeling and Evolution.

Penulis: Jiaying Liu; Hansong Nie; Shihao Li; Xiangtai Chen; Huazhu Cao; Jing Ren; Ivan Lee; Feng Xia.

Publikasi: Big Data Research, Volume 25 (2021) 100236 (Elsevier). DOI: 10.1016/j.bdr.2021.100236.

2. Data

Sumber data: COVID-19 Open Research Dataset (CORD-19), yang menggabungkan metadata dari PMC, BioRxiv, MedRxiv, dan WHO COVID-19 Database. Korpus dibatasi pada publikasi pasca-2020 dengan kata kunci “COVID-19”, “SARS-CoV-2”, atau “2019-NCOV” pada judul/abstrak.

Skala data: 6.392 publikasi (mis. 714 arXiv, 1.307 PubMed, 1.648 Elsevier, 66 CHI, 480 WHO, 2.162 MedRxiv, 555 BioRxiv).

Fitur utama:

- Abstrak (teks) sebagai input LDA.
- Metadata waktu (jendela 7 hari), sumber venue, dan bidang/subbidang via pencocokan ke Microsoft Academic Graph.
- Referensi/sitasi untuk analisis bibliometrik (>118.000 referensi; >60.000 artikel unik setelah penyaringan).
- Output turunan: vektor distribusi topik 50 dimensi per paper.

3. Proses (metodologi)

(a) Seleksi & pemetaan bidang

Paper COVID-19 disaring dari CORD-19 lalu dipetakan ke Microsoft Academic Graph (MAG) untuk informasi bidang.

(b) Pra-pemrosesan abstrak

Deteksi bahasa (Langid), lowercasing, tokenisasi, stopword removal, lalu bag-of-words.

(c) Topic modeling & evolusi

LDA menghasilkan 50 topik; dihitung ck (proporsi kumulatif) dan rk (popularitas bulanan). Analisis temporal memakai jendela 7 hari (1 Jan–20 Mei).

(d) Ko-okurensi topik

Matriks 50×50 untuk melihat topik yang sering muncul bersama.

(e) Paper/topik inovatif

Representasi topik 50-dimensi $\rightarrow$ K-Means (15 kelas) $\rightarrow$ indeks inovasi (IA) yang menggabungkan ‘foreseeing ability’, jarak ke pusat klaster (L1), dan bobot reputasi venue; dipilih 10 paper inovatif.

4. Model

- LDA (50 topik): memetakan fokus riset COVID-19 dan pergeserannya dari waktu ke waktu.
- Metrik ck & rk : mengidentifikasi topik paling populer dan yang sedang meningkat.
- Ko-okurensi: memetakan hubungan kuat antar topik.
- K-Means + indeks inovasi (IA): menyortir paper yang “mendahului” tren dan berpotensi jadi karya kunci.

5. Hasil (temuan utama)

- Bidang riset awal didominasi Biology dan Medicine; seiring waktu meningkat juga topik psikologi, ekonomi, dan dampak sosial.
- Pola sitasi menunjukkan keterkaitan kuat dengan literatur SARS (pasca-2002) dan MERS (banyak referensi 2010–2019); bidang referensi teratas Biology–Medicine–Chemistry, disusul Computer Science.
- Topik “hottest” mencakup kontrol sosial (lockdown/tracing/distancing) dan isu klinis/komorbiditas; topik “most popular” banyak terkait estimasi transmisi, diagnosis/konfirmasi, deep learning, dan model peramalan.
- Pasangan topik ko-muncul teratas menegaskan keterkaitan antara peramalan/estimasi wabah dan kebijakan kontrol sosial.
- 10 paper inovatif yang disorot (umumnya Jan–Mar 2020) banyak berkaitan dengan panduan/karakteristik klinis dan estimasi transmisi, serta pelajaran dari SARS/MERS.

Komparasi Jurnal 1 dan Jurnal 2

Ringkas perbandingan:

- Objek & tujuan
 - Jurnal 1: memetakan narasi antivaksin/misinformasi di Twitter dan menyediakan dataset Tweet ID untuk riset lanjutan.
 - Jurnal 2: memetakan perkembangan riset ilmiah COVID-19 melalui topic modeling publikasi (tren, keterkaitan topik, paper inovatif).
- Data & skala
 - Jurnal 1: 1,83 juta tweet (streaming) + 135,95 juta tweet historis akun.
 - Jurnal 2: 6.392 paper + >118.000 referensi/sitasi.
- Fitur yang dipakai
 - Jurnal 1: hashtag, URL/domain, metadata akun (lokasi/verifikasi), dan waktu posting.
 - Jurnal 2: abstrak, metadata waktu, bidang (MAG), serta referensi/sitasi.
- Metode/model
 - Jurnal 1: snowball keyword; Louvain untuk kluster narasi; bias politik berbasis media diet; tagging kredibilitas domain.
 - Jurnal 2: LDA 50 topik; metrik ck/rk; ko-okurensi topik; K-Means + indeks inovasi (IA).
- Temuan utama
 - Jurnal 1: ekosistem antivaksin condong konservatif dan banyak berbagi sumber kredibilitas rendah; narasi terbagi menjadi beberapa kluster.
 - Jurnal 2: fokus riset awal dominan biomedis lalu meluas; sitasi kuat ke SARS/MERS; topik estimasi/prediksi & kontrol sosial saling terkait.

Kesimpulan: keduanya sama-sama memakai big data untuk memahami pandemi, tetapi pada level berbeda (arus informasi publik vs arus pengetahuan ilmiah). Menggabungkan keduanya dapat membantu merancang intervensi komunikasi kesehatan yang berbasis bukti sekaligus peka terhadap dinamika misinformasi.